第七章 运行时环境

冯 洋

运行时刻环境

- 运行时刻环境
  - 为数据分配安排存储位置
  - 确定访问变量时使用的机制
  - 过程之间的连接
  - 参数传递
  - 和操作系统、输入输出设备相关的其它接口
- 主题
  - 存储管理：栈分配、堆管理、垃圾回收
  - 对变量、数据的访问

存储分配的典型方式

- 目标程序的代码放置在代码区
- 静态区、堆区、栈区分别放置不同类型生命期的数据值
- 实践中，栈是由低地址向高地址增长，而堆是由高地址向低地址增长

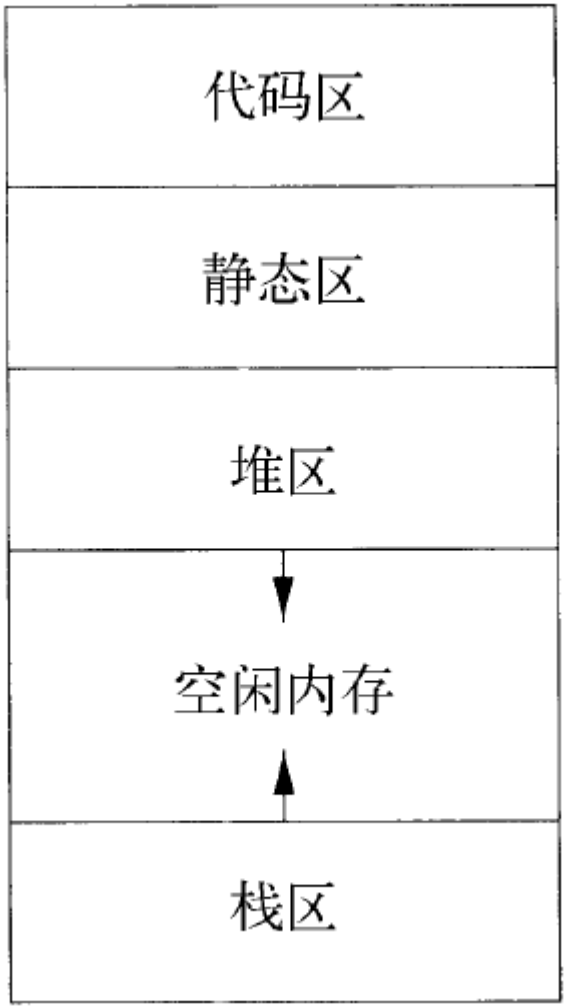

静态和动态存储分配

- 静态分配
  - 编译器在编译时刻就可以做出存储分配决定，不需要考虑程序运行时刻的情形
  - 全局变量
- 动态分配
  - 栈式存储：和过程的调用/返回同步进行分配和回收，值的生命期和过程生命期相同
  - 堆存储：数据对象比创建它的过程调用更长寿
    - 手工进行回收：C++/C…
    - 垃圾回收机制：Java/C#/Python…

栈式分配

- 主要内容
  - 活动树
  - 活动记录
  - 调用代码序列
  - 栈中的变长数据

活动树

- 过程调用（过程活动）在时间上总是嵌套的
  - 后调用的先返回
  - 因此用栈式分配来分配过程活动所需内存空间
- 程序运行的所有过程活动可以用树表示
  - 每个结点对应于一个过程活动
  - 根结点对应于main过程的活动
  - 过程p的某次活动对应的结点的所有子结点：此次活动所调用的各个过程活动（从左向右，表示调用的先后顺序）

活动树的例子（1）

- 程序：P277，图7-2
- 过程调用（返回）序列和活动树的前序（后序）遍历对应
- 假定当前活动对应结点N，那么所有尚未结束的活动对应于N及其祖先结点。

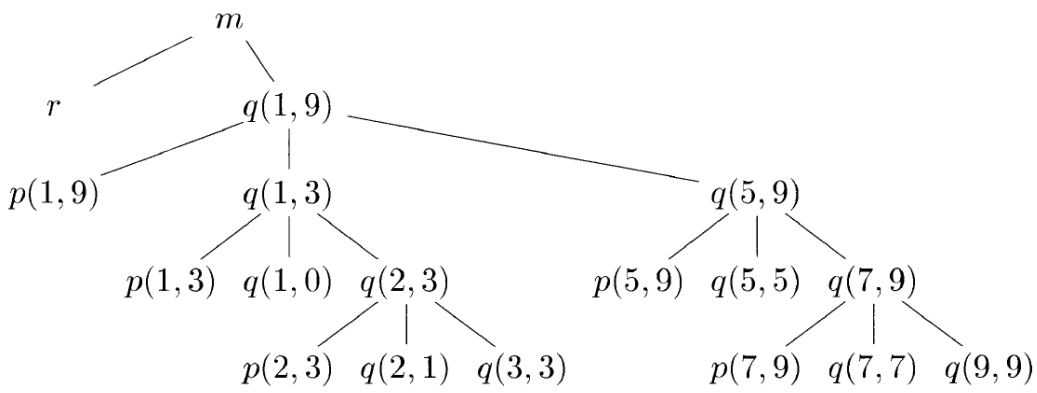


```
enter main()
    enter readArray()
    leave readArray()
    enter quicksort(1,9)
        enter partition(1,9)
        leave partition(1,9)
        enter quicksort(1,3)
            ...
        leave quicksort(1,3)
        enter quicksort(5,9)
            ...
        leave quicksort(5,9)
    leave quicksort(1,9)
leave main()
```

图 7-2 中程序的可能的活动序列

活动记录

- 过程调用和返回由控制栈进行管理
- 每个活跃的活动对应于栈中的一个活动记录
- 活动记录按照活动的开始时间，从栈底到栈顶排列

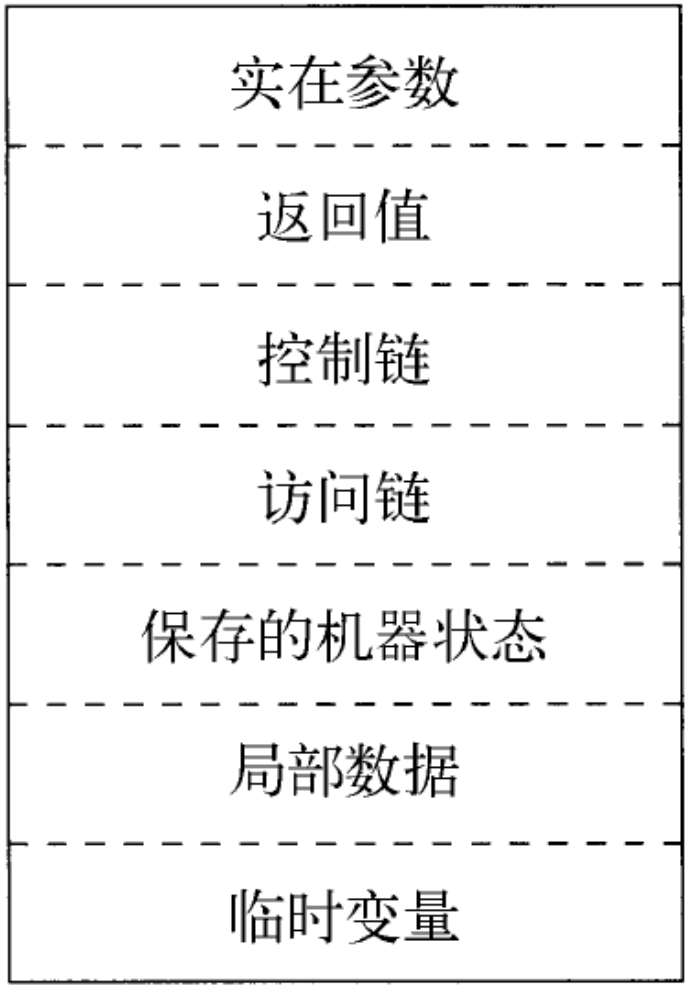

运行时刻栈的例子

- a[11]为全局变量
- main没有局部变量
- r有局部变量i
- q的局部变量i，和参数m, n

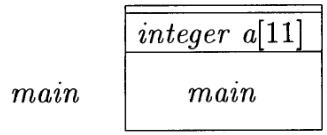

a) γ被弹出栈

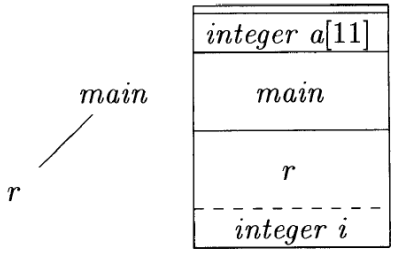

b) γ被激活

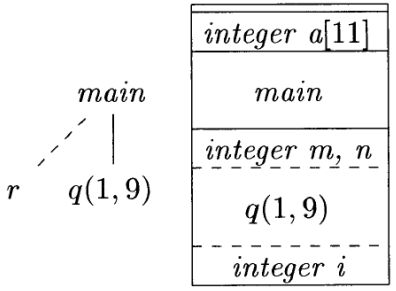

c) γ被弹出栈，$q(1,9)$被压栈

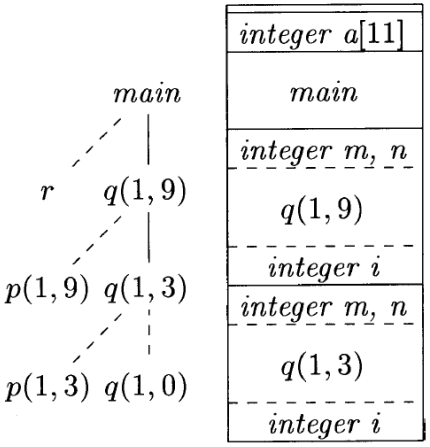

d) 控制返回到 $q(1,3)$

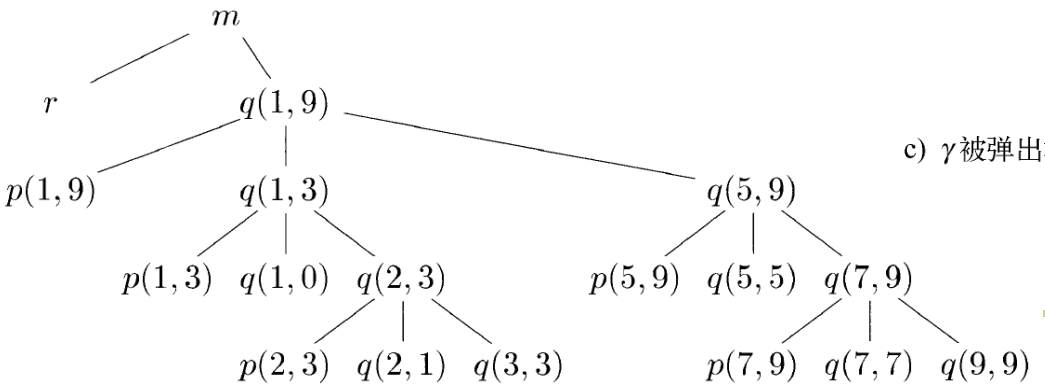

调用代码序列

- 调用代码序列(calling sequence)为活动记录分配空间，填写记录中的信息
- 返回代码序列(return sequence)恢复机器状态，使调用者继续运行
- 调用代码序列会分割到调用者和被调用者中
  - 根据源语言、目标机器、操作系统的限制，可以有不同的分割方案
  - 把代码尽可能放在被调用者中

调用/返回代码序列的要求

- 数据方面
  - 能够把参数正确地传递给被调用者
  - 能够把返回值传递给调用者
- 控制方面
  - 能够正确转到被调用过程的代码开始位置
  - 能够正确转回调用者的调用位置（的下一条指令）
- 调用代码序列和活动记录的布局相关

活动记录的布局原则

代码逐行扫描，栈的变化情况

- 调用者和被调用者之间传递的值放在被调用者活动记录的开始位置
- 固定长度的项放在中间位置
  - 控制链、访问链、机器状态字段
- 早期不知道大小的项在活动记录尾部
- 栈顶指针(top_sp)通常指向固定长度字段的末端

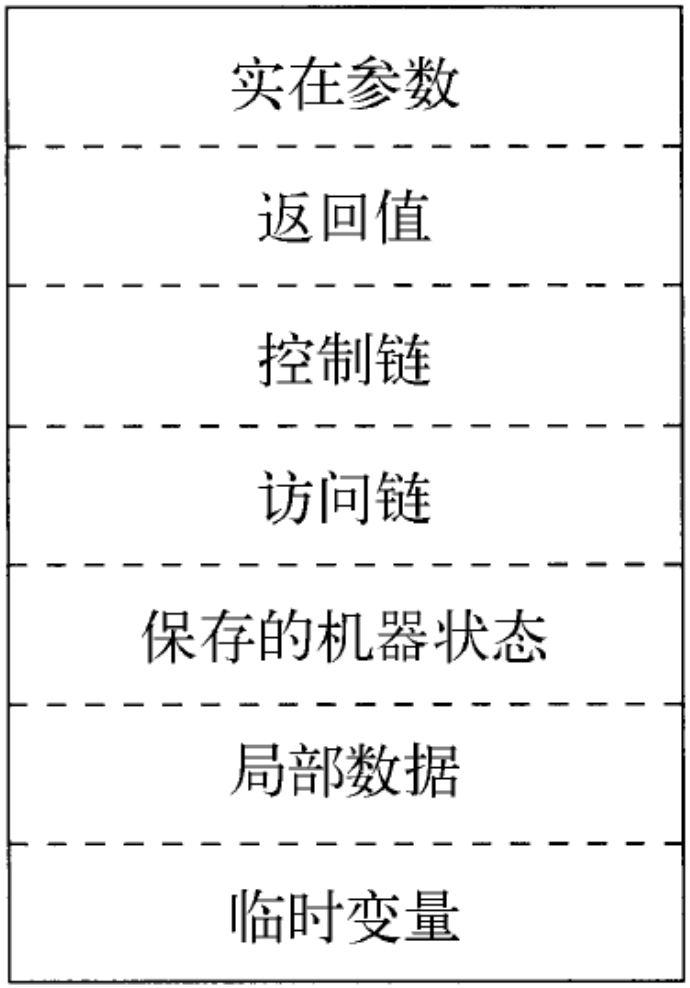

调用代码序列的例子

- 调用代码序列（Calling sequence）
  - 调用者计算实在参数的值
  - 将返回地址和原top_sp存放到被调用者的活动记录中。调用者增加top_sp的值（越过了局部数据、临时变量、被调用者的参数、机器状态字段）
  - 被调用者保存寄存器值和其他状态字段
  - 被调用者初始化局部数据、开始运行
- 返回代码序列（Return sequence）
  - 被调用者将返回值放到和参数相邻的位置
  - 恢复top_sp和寄存器，跳转到返回地址

调用者/被调用者的活动记录

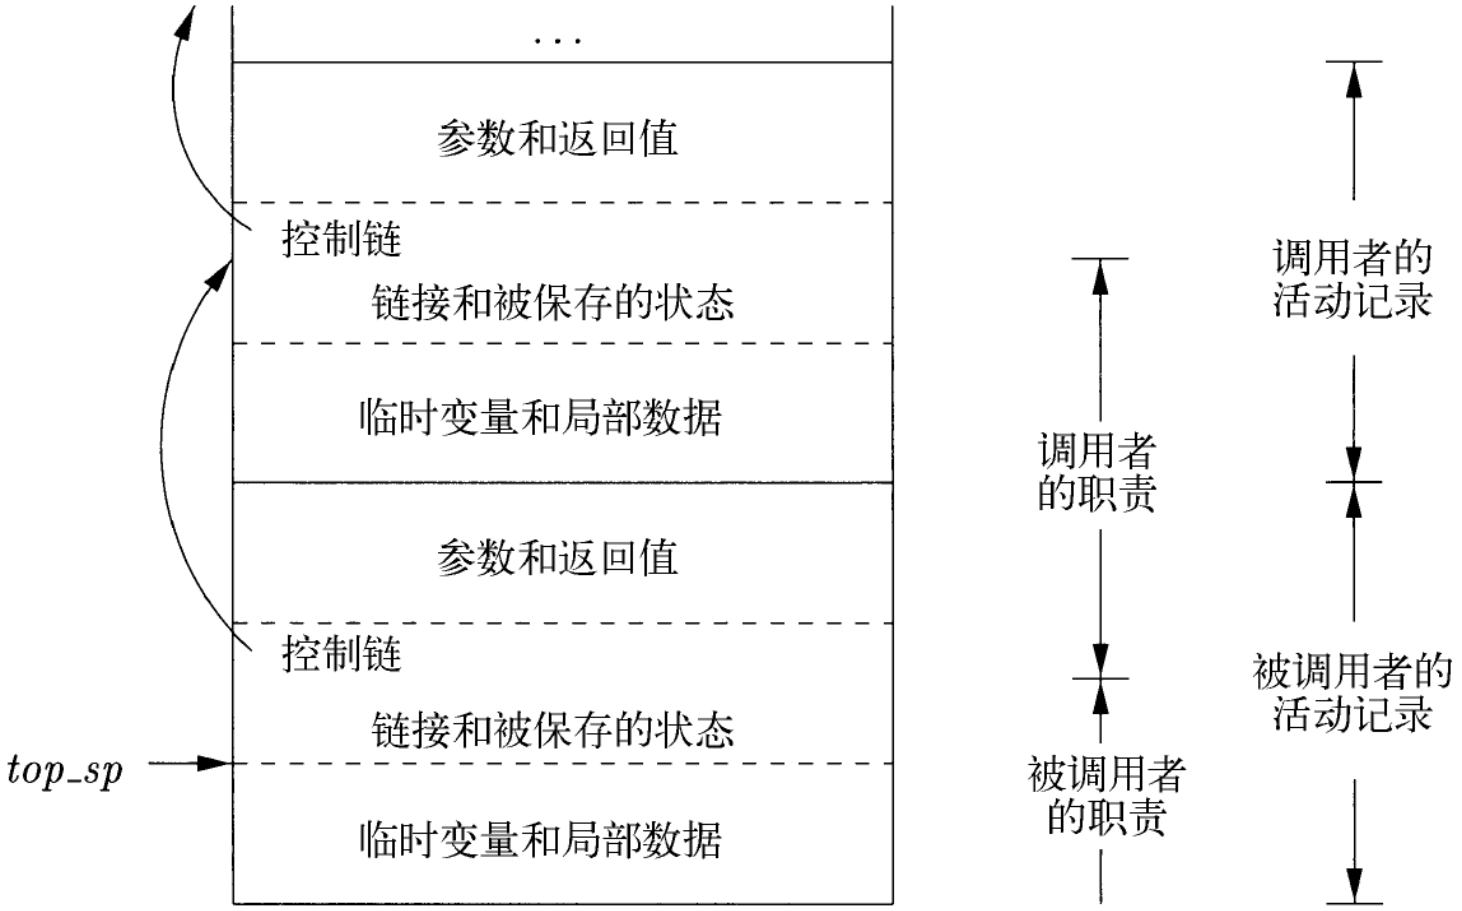

图 7-7　调用者和被调用者之间的任务划分

栈中的变长数据

- 看一个实际的例子

栈中的变长数据

- 如果数据对象的生命期局限于过程活动的生命期，就可以分配在运行时刻栈中
  - 变长数组也可以放在栈中
- top指向实际的栈顶
- top_sp用于寻找顶层记录的定长字段

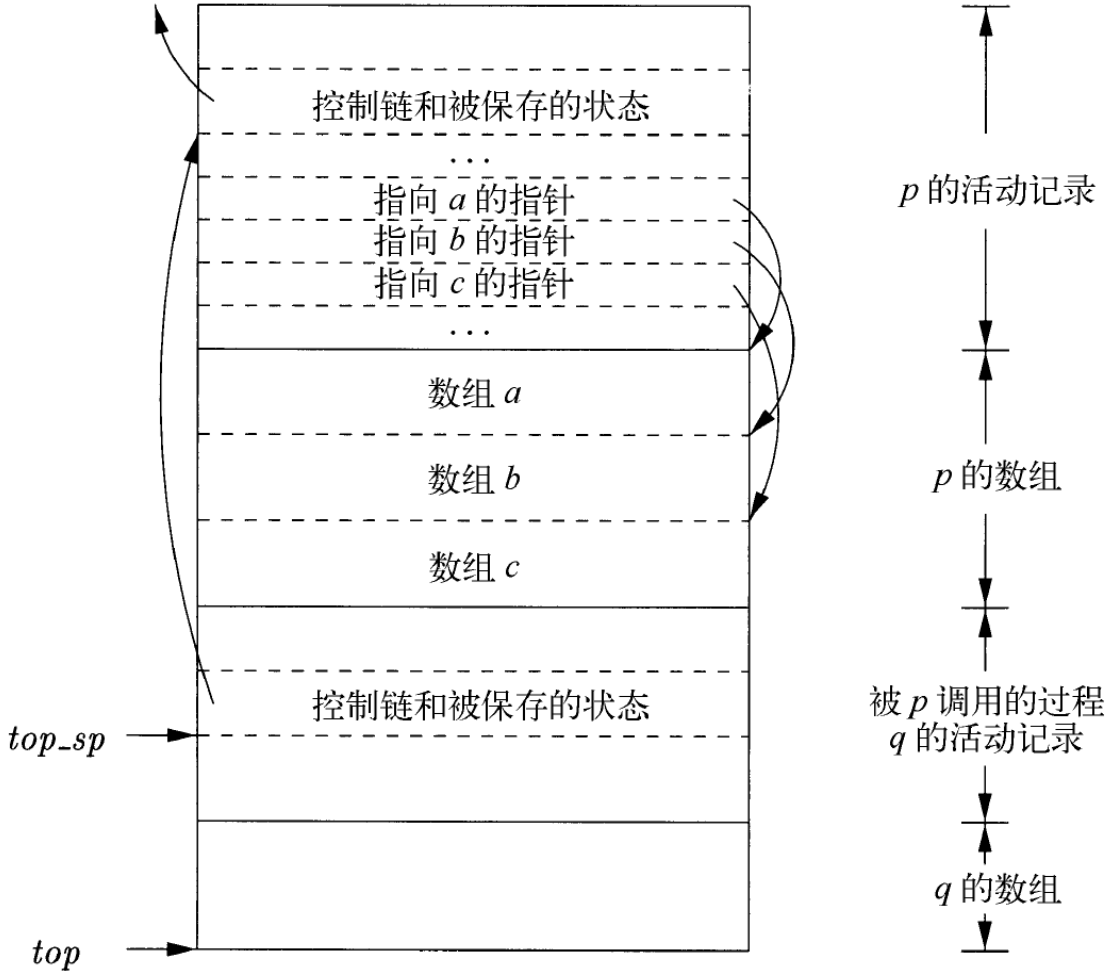

图 7-8　访问动态分配的数组

非局部数据的访问（无嵌套过程）

- 没有嵌套过程时的数据访问
  - C语言中，每个函数能够访问的变量
    - 函数的局部变量：相对地址已知，且存放在当前活动记录内，top_sp指针加上相对地址即可访问
    - 全局变量：在静态区，地址在编译时刻可知
  - 很容易将C语言的函数作为参数进行传递
    - 参数中只需包括函数代码的开始地址。
    - 在函数中访问非局部变量的模式很简单，不需要考虑过程是如何激活的

非局部数据的访问（嵌套声明过程）

- PASCAL中，如果过程A的声明中包含了过程B的声明，那么B可以使用在A中声明的变量。
- 当B的代码运行时，如果它使用的是A中的变量。那么这个变量指向运行栈中最上层的同名变量。
- 但是，我们不能通过嵌套层次直接得到A的活动记录的相对位置，必须通过访问链访问

```
void A()
{
        int     x,y;
        void    B()
        {       int b;
                x = b+y;
        }
        void    C(){B();}
    C();
    B();
}
```

当A调用C，C又调用B时：

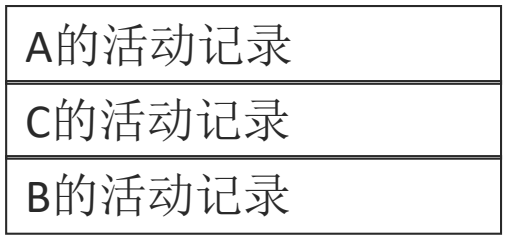

当A直接调用B时：

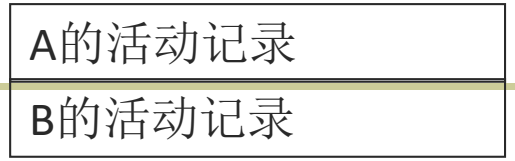

一个支持嵌套声明的例子

- ML是一种函数式语言.

  变量一旦被声明并初始化就不会在改变，只有少数几个例外.

- 定义变量并设定它们不可更改的初始值的语句有如下形式

  val <name> = (expression)

- 函数使用如下语法进行定义

  fun<name> (<arguments>) = <body>

- 使用下列形式的let语句来定义函数体

  let<list of definitions> in <statements> end

  其中，定义通常是val或fun语句.

  每个这样的定义的作用域包括从该定义之后直到in为止的所有定义，及直到end为止的所有语句. 函数可嵌套地定义. 如函数p的函数体可能包括一个let语句，而该语句又包含了另一个函数q的定义.

嵌套深度

- 嵌套深度是正文概念，可以根据源程序静态地确定
  - 不内嵌于任何其他过程中的过程，嵌套深度为1
  - 嵌套在深度为i的过程中的过程，深度为i+1

深度为1

sort

深度为2

readArray，exchange，quicksort

深度为3

partition

```
1) fun sort(inputFile, outputFile) =
       let
2)         val a = array(11,0);
3)         fun readArray(inputFile) = ··· ;
4)               ··· a ··· ;
5)         fun exchange(i,j) =
6)               ··· a ··· ;
7)         fun quicksort(m,n) =
               let
8)                 val v = ··· ;
9)                 fun partition(y,z) =
10)                      ··· a ··· v ··· exchange ···
               in
11)                ··· a ··· v ··· partition ··· quicksort
               end
       in
12)        ··· a ··· readArray ··· quicksort ···
       end;
```

访问链

- 访问链
  - 当被调用过程需要其他地方的某个数据时需要使用访问链进行定位
  - 如果过程p在声明时嵌套在过程q的声明中，那么p的活动记录中的访问链指向最上层的q的活动记录
  - 从栈顶活动记录开始，访问链形成了一个链路，嵌套深度沿着链路逐一递减

访问链

- 设深度为n_p的过程p访问变量x，而变量x在深度为n_q的过程中声明，那么
  - n_p-n_q在编译时刻已知
  - 从当前活动记录出发，沿访问链前进n_p-n_q次找到的活动记录中的x就是要找的变量位置
  - x相对于这个活动记录的偏移量在编译时刻已知

访问链的例子

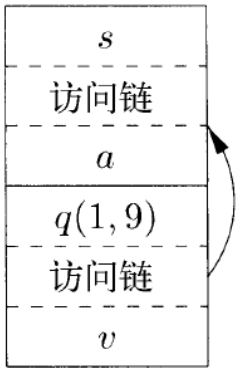

a)

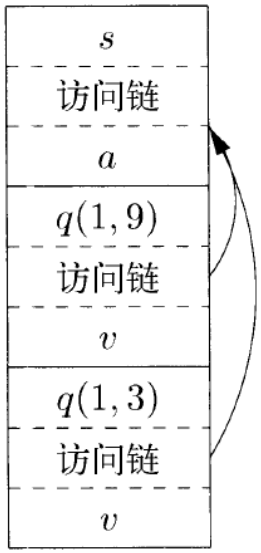

b)

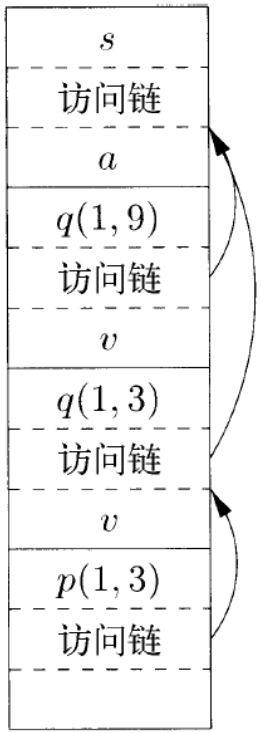

c)

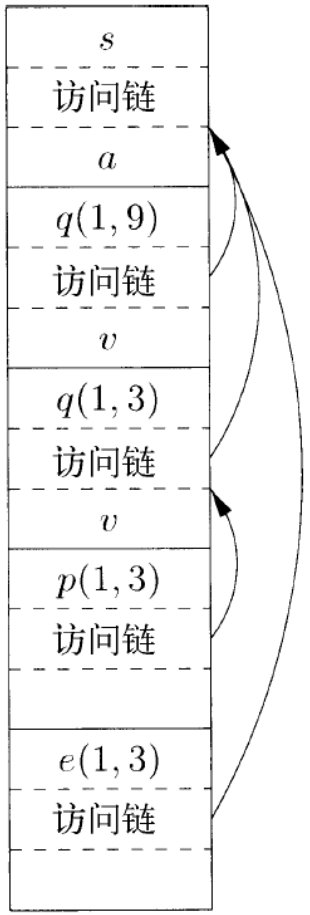

d)

```
 1) fun sort(inputFile, outputFile) =
        let
 2)         val a = array(11,0);
 3)         fun readArray(inputFile) = ··· ;
 4)               ··· a ··· ;
 5)         fun exchange(i,j) =
 6)               ··· a ··· ;
 7)         fun quicksort(m,n) =
                let
 8)                  val v = ··· ;
 9)                  fun partition(y,z) =
10)                       ··· a ··· v ··· exchange ···
                in
11)                 ··· a ··· v ··· partition ··· quicksort
                end
        in
12)         ··· a ··· readArray ··· quicksort ···
        end;
```

访问链的维护（直接调用过程）

- 当过程q调用过程p时，访问链的变化
  - p的深度大于q：根据作用域规则，p必然在q中直接定义；那么p的访问链指向当前活动记录
    - s调用q(1,9)
  - 递归调用（p=q）：新活动记录的访问链等于当前记录的访问链
    - q(1,9)调用q(1,3)
  - p的深度小于等于q的深度：此时必然有过程r，p直接在r中定义，而q嵌套在r中；p的访问链指向栈最高的r的活动记录
    - p调用exchange

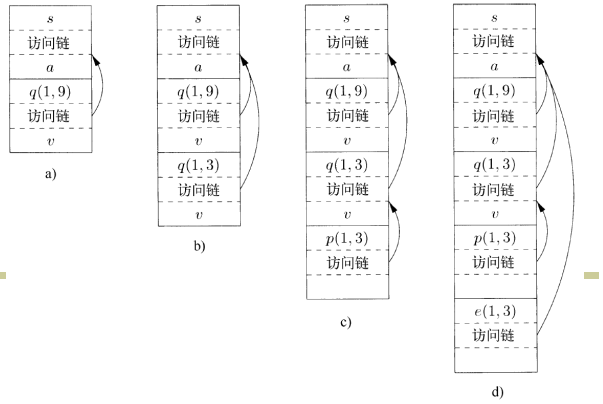

访问链的维护：访问链的定义+作用域规则

访问链的维护（过程指针型参数）

- 在传递过程指针参数时，过程型参数中不仅包含过程的代码指针，还包括正确的访问链

显示表

- 用访问链访问数据时，访问开销和嵌套深度差有关
- 使用显示表可以提高效率，访问开销为常量
- 显示表：数组d为每个嵌套深度保留一个指针
  - 指针d[i]指向栈中最高的、嵌套深度为i的活动记录。
  - 如果程序p中访问嵌套深度为i的过程q中声明的变量x，那么d[i]直接指向相应的（必然是q的）活动记录
    - 注意：i在编译时刻已知
- 显示表的维护
  - 调用过程p时，在p的活动记录中保存$d[n_p]$的值，并将$d[n_p]$设置为当前活动记录。
  - 从p返回时，恢复$d[n_p]$的值。

显示表的例子

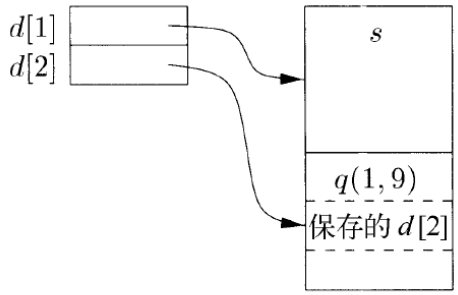

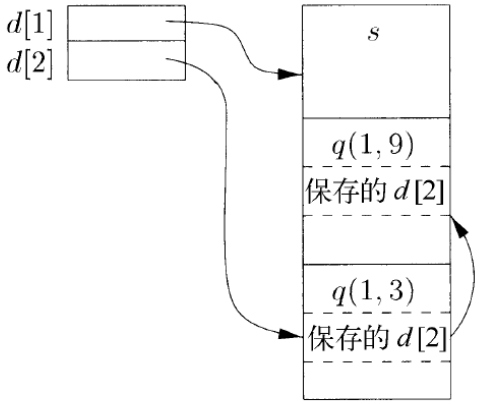

b)

q(1,9)调用q(1,3)时，q的深度为2

q(1,3)调用p，p的深度为3

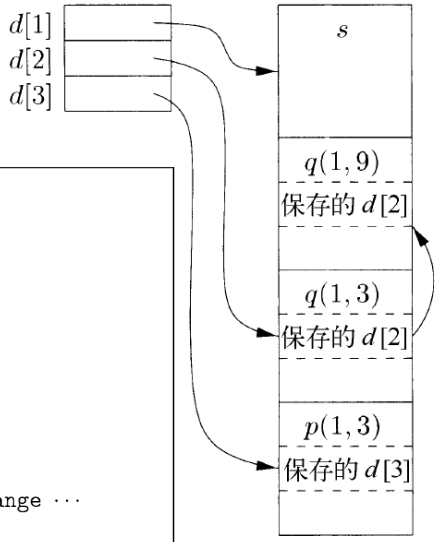

a)

```
1) fun sort(inputFile, outputFile) =
       let
2)         val a = array(11,0);
3)         fun readArray(inputFile) = ··· ;
4)               ··· a ··· ;
5)         fun exchange(i,j) =
6)               ··· a ··· ;
7)         fun quicksort(m,n) =
               let
8)                 val v = ··· ;
9)                 fun partition(y,z) =
10)                     ··· a ··· v ··· exchange ···
               in
11)                ··· a ··· v ··· partition ··· quicksort
               end
       in
12)        ··· a ··· readArray ··· quicksort ···
       end;
```

c)

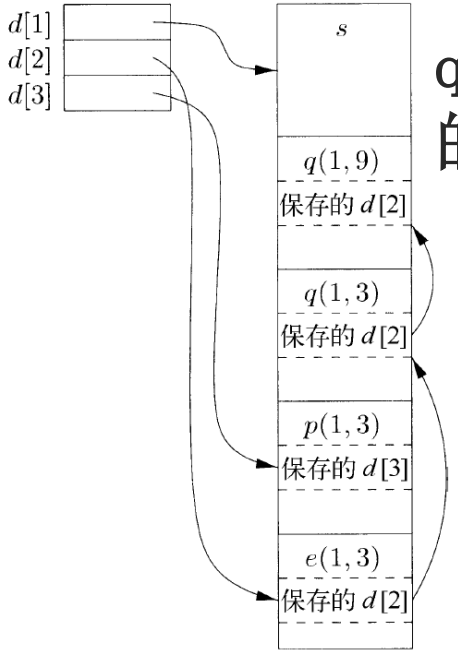

d)

q调用e，e的深度为2

堆管理

- 堆空间
  - 用于存放生命周期不确定、或生存到被明确删除为止的数据对象
  - 例如：new生成的对象可以生存到被delete为止
  - malloc申请的空间生存到被free为止
- 存储管理器
  - 分配/回收堆区空间的子系统
  - 根据语言而定
    - C、C++需要手动回收空间
    - Java可以自动回收空间（垃圾收集）

存储管理器

- 基本功能
  - 分配：为每个内存请求分配一段连续的、适当大小的堆空间
    - 首先从空闲的堆空间分配
    - 如果不行则从操作系统中获取内存、增加堆空间
  - 回收：把被回收的空间返回空闲空间缓冲池，以满足其他内存需求
- 评价存储管理器的特性
  - 空间效率：使程序需要的堆空间最小，即减小碎片
  - 程序效率：充分运用内存系统的层次，提高效率
  - 低开销：使分配/收回内存的操作尽可能高效

程序中的局部性

- 局部性

大部分程序表现出高度的局部性 – 程序的大部分运行时间花费在相对较小的一部分代码中（此时可能只涉及固定的一小部分数据）。

堆空间的碎片问题

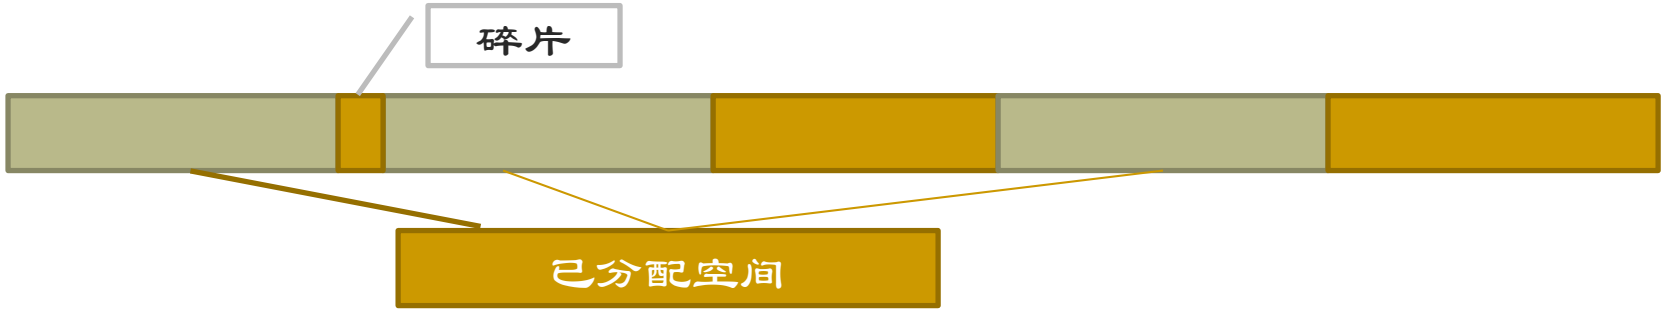

- 随着程序分配/回收内存，堆区逐渐被割裂成为若干空闲存储块（窗口，hole）和已用存储块的交错
- 分配一块内存时，通常是把一个窗口的一部分分配出去，其余部分成为更小的块
- 回收时，被释放的存储块被放回缓冲池。通常要把连续的窗口接合成为更大的窗口

堆空间分配方法

- Best-Fit
  - 总是将请求的内存分配在满足请求的最小的窗口中
  - 好处：可以将大的窗口保留下来，应对更大的请求
- First-Fit
  - 总是将对象放置在第一个能够容纳请求的窗口中
  - 放置对象时花费时间较少，但是总体性能较差
  - 但是first-fit的分配方法通常具有较好的数据局部性
    - 同一时间段内的生成的对象经常被分配在连续的空间内

使用容器的堆管理方法

- 设定不同大小的空闲块规格，相同规格的块放在同一容器中
- 较小的（较常用的）尺寸设置较多的容器
- 比如GNU的C编译器将所有存储块对齐到8字节边界
  - 空闲块的尺寸大小
    - 16, 24, 32, 40, …, 512
    - 大于512的按照对数划分：每个容器的最小尺寸是前一个容器的最小尺寸的两倍
    - 荒野块：可以扩展的内存块
  - 分配方法
    - 对于小尺寸的请求，直接在相应容器中找
    - 大尺寸的请求，在适当的容器中寻找适当的空闲块
    - 可能需要分割内存块
    - 可能需要从荒野块中分割出更多的块

管理和接合空闲空间

- 当回收一个块时，可以把这个块和相邻的块接合起来，构成更大的块
- 支持相邻块接合的数据结构
  - 边界标记：在每一块存储块的两端，分别设置一个free/used位；相邻的位置上存放字节总数
  - 双重链接的、嵌入式的空闲块列表：列表的指针存放在空闲块中、用双向指针的方式记录了有哪些空闲块

例子

- 相邻的存储块A、B、C
  - 当回收B时，通过对free/used位的查询，可以知道B左边的A是空闲的，而C不空闲。
  - 同时还可以知道A、B合并为长度为300的块
  - 修改双重链表，把A替换为A、B接合后的空闲块
- 注意：双重链表中一个结点的前驱并不一定是它邻近的块

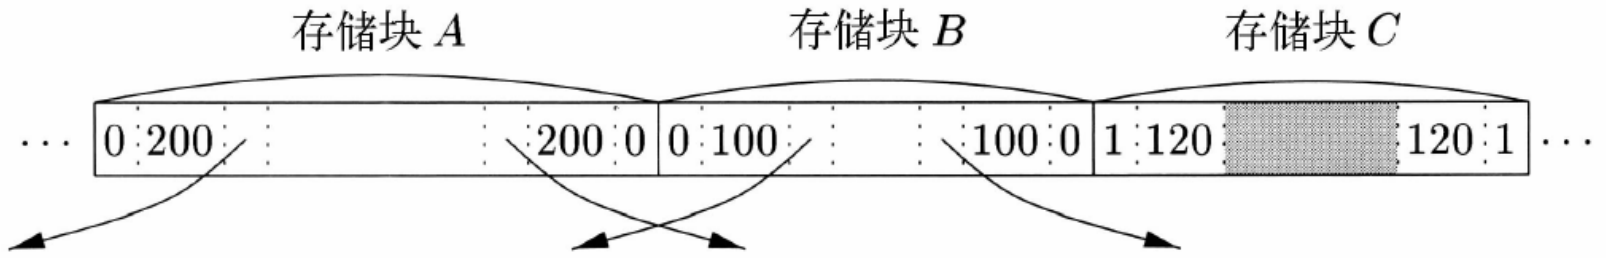

处理手工存储管理

- 两大问题
  - 内存泄露：未能删除不可能再被引用的数据
  - 悬空指针引用：引用已被删除的数据
- 其他问题
  - 空指针访问/数组越界访问
- 解决方法
  - 自动存储管理
  - 正确的编程模式

正确的编程模式（1）

- 对象所有者（Object ownership）
  - 每个对象总是有且只有一个所有者（指向此对象的指针）；只有通过Owner才能够删除这个对象
  - 当Owner消亡时，这个对象要么也被删除，要么已经被传递给另一个owner
    - 语句v=new ClassA；创建的对象的所有者为v
    - 即将对v进行赋值的时刻（v的值即将消亡）
      - 要么v已经不是它所指对象的所有者；比如g=v可以把v的ownership传递给g
      - 要么需要在返回/赋值之前，执行delete v操作
  - 编程时需要了解各个指针在不同时刻是否owner
  - 防止内存泄漏，避免多次删除对象。不能解决悬空指针问题

正确的编程模式（2）

- 引用计数
  - 每个动态分配的对象附上一个计数：记录有多少个指针指向这个对象
  - 在赋值/返回/参数传递时维护引用计数的一致性
  - 在计数变成0之时删除这个对象
  - 可以解决悬空指针问题；但是在递归数据结构中仍然可能引起内存泄漏
  - 需要较大的运行时刻开销
- 基于区域的分配
  - 将一些生命期相同的对象分配在同一个区域中
  - 整个区域同时删除

垃圾回收

- 垃圾
  - 狭义：不能被引用（不可达）的数据
  - 广义：不需要再被引用的数据
- 垃圾回收：自动回收不可达数据的机制，解除了程序员的负担
- 使用的语言
  - Java、Perl、ML、Modula-3、Prolog、Smalltalk

垃圾回收器的设计目标

- 基本要求：
  - 语言必须是类型安全的：保证回收器能够知道数据元素是否为一个指向某内存块的指针
  - 类型不安全的语言：C，C++
- 性能目标
  - 总体运行时间：不显著增加应用程序的总运行时间
  - 空间使用：最大限度地利用可用内存
  - 停顿时间：当垃圾回收机制启动时，可能引起应用程序的停顿。这个停顿应该比较短
  - 程序局部性：改善空间局部性和时间局部性

可达性

- 直观地讲，可达性就是指一个存储块可以被程序访问到
- 根集：不需要指针解引用就可以直接访问的数据
  - Java：静态成员、栈中变量
- 可达性
  - 根集的成员都是可达的
  - 对于任意一个对象，如果指向它的一个指针被保存在可达对象的某字段中、或数组元素中，那么这个对象也是可达的
- 性质
  - 一旦一个对象变得不可达，它就不会再变成可达的

改变可达对象集合的操作

- 对象分配：返回一个指向新存储块的引用
- 参数传递/返回值：对象引用从实在参数传递到形式参数，从返回值传递给调用者
- 引用赋值：u=v；v的引用被复制到u中，u中原来的引用丢失。可能使得u原来指向的对象变得不可达，并且递归地使得更多对象变得不可达
- 过程返回：活动记录出栈，局部变量消失，根集变小；可能使得一些对象变得不可达

垃圾回收方法分类

- 跟踪相关操作，捕获对象变得不可达的时刻，回收对象占用的空间
- 在需要时，标记出所有可达对象、回收其它对象

基于引用计数的垃圾回收器

- 每个对象有一个用于存放引用计数的字段，并按照如下方式维护
  - 对象分配：引用计数设为1
  - 参数传递：引用计数加1
  - 引用赋值：u=v：u指向的对象引用减1、v指向的对象引用加1
  - 过程返回：局部变量指向对象的引用计数减1
- 如果一个对象的引用计数为0，在删除对象之前，此对象中各个指针所指对象的引用计数减1
- 回收器有缺陷，可能引起内存泄漏
- 开销较大、但是不会引起停顿

引用计数的例子

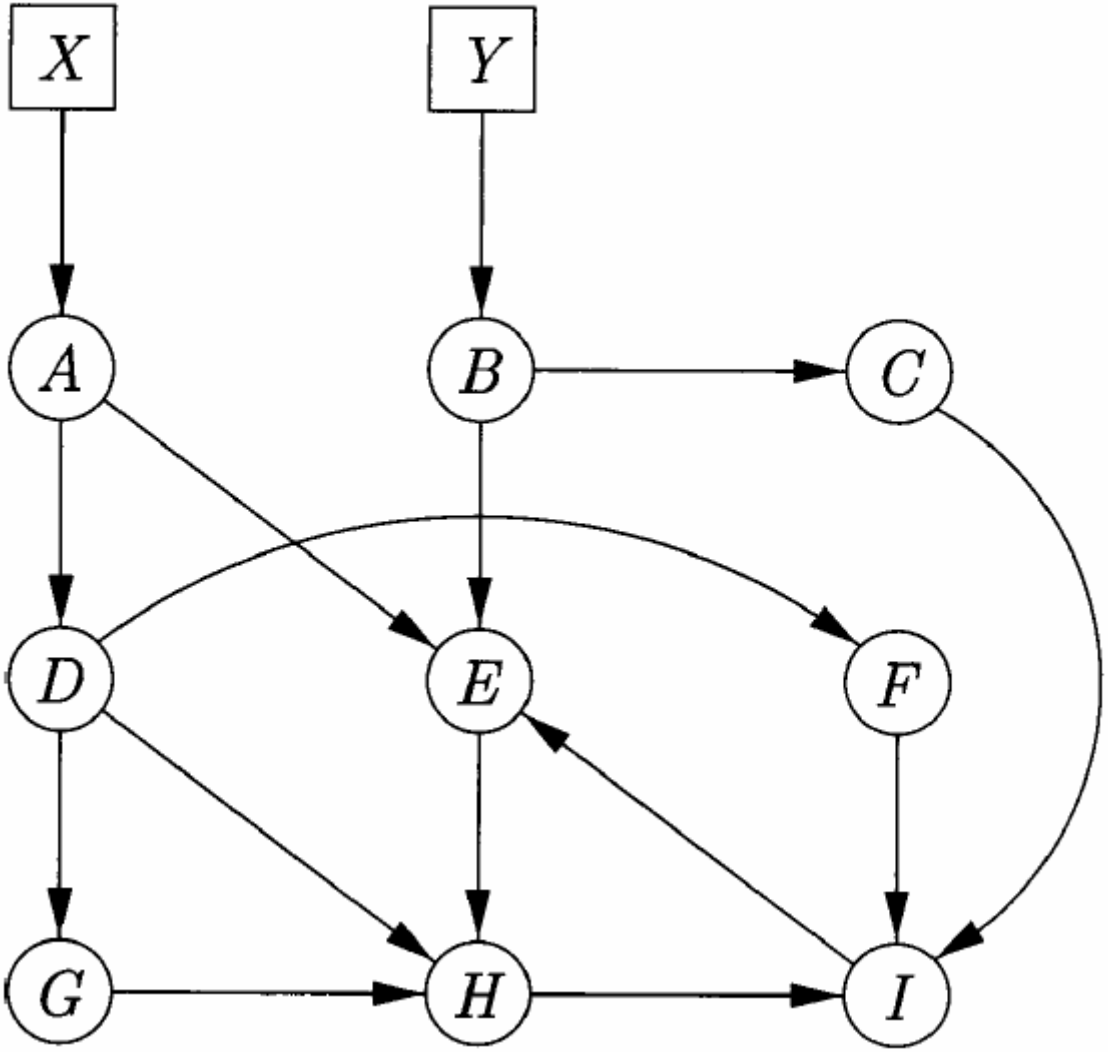

- 考虑如下操作：
  - y=x
  - y是当前函数f的局部变量，且f返回
- 修改计数后总是先考虑是否释放
- 释放一个对象之前总是先处理对象内部的指针

循环垃圾的例子

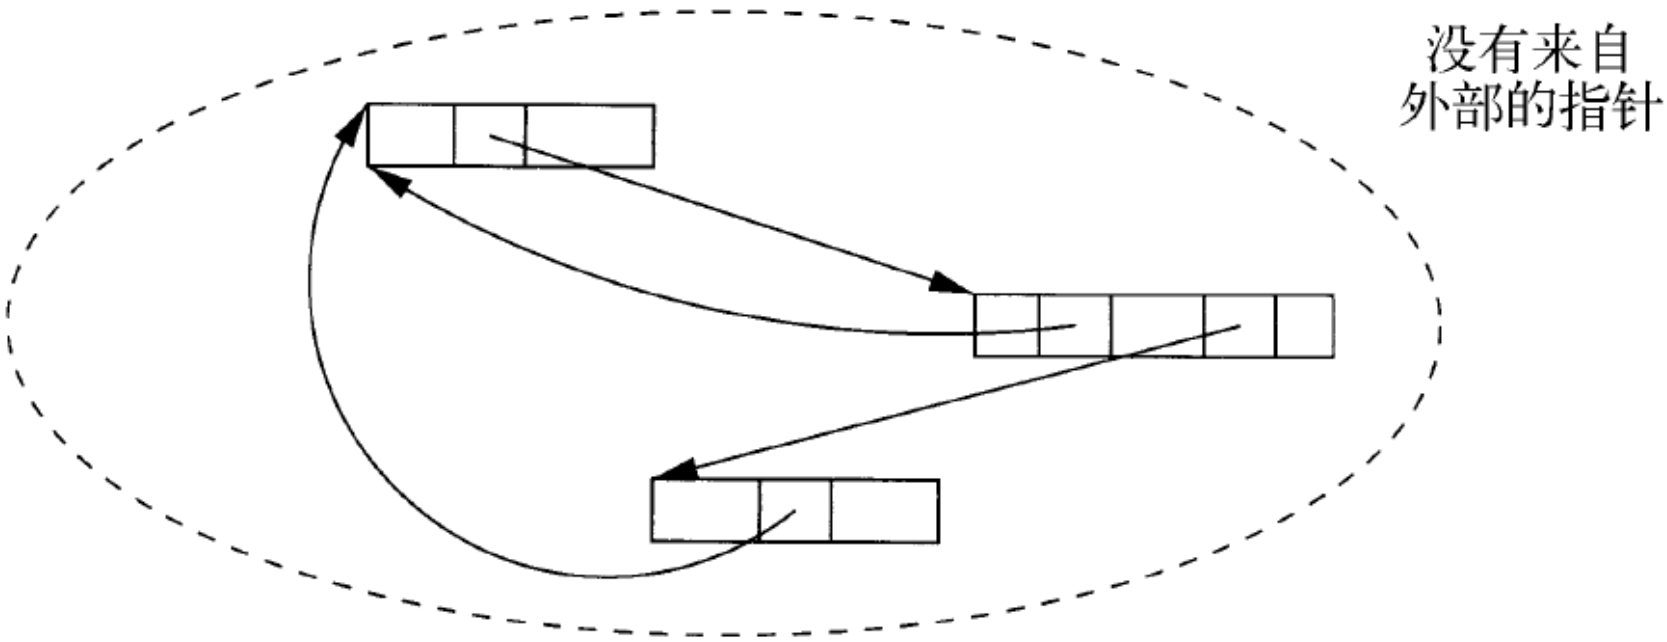

图 7-18　一个不可达的循环数据结构

基于跟踪的垃圾回收

- 标记-清扫式垃圾回收
- 标记-清扫式垃圾回收的优化
- 标记并压缩垃圾回收

标记-清扫式垃圾回收

- 一种直接的、全面停顿的算法
- 分成两个阶段
  - 标记：从根集开始，跟踪并标记出所有可达对象；
  - 清扫：遍历整个堆区，释放不可达对象；

会出现停顿，会将程序代码挂起

- 如果我们把数据对象看作顶点，引用看作有向边，那么标记的过程实际上是从根集开始的图遍历的过程

标记-清扫式垃圾回收

- 该算法主要包括两步，
  - mark，从 root 开始进行树遍历，每个访问的对象标注为「使用中」
  - sweep，扫描整个内存区域，对于标注为「使用中」的对象去掉该标志，对于没有该标注的对象直接回收掉

标记-清扫式垃圾回收

- 该算法的缺点有：
  - 在进行 GC 期间，整个系统会被挂起（暂停，Stop-the-world），所以在一些实现中，会采用各种措施来减少这个暂停时间
  - heap 容易出现碎片。实现中一般会进行 move 或 compact。（需要说明一点，所有 heap 回收机制都会这个问题）
  - 在 GC 工作一段时间后，heap 中连续地址上存在 age 不同的对象，这非常不利于引用的本地化（locality of reference）
  - 回收时间与 heap 大小成正比

标记-清扫式垃圾回收

- 该算法的缺点有：
  - 在进行 GC 期间，整个系统会被挂起（暂停，Stop-the-world），所以在一些实现中，会采用各种措施来减少这个暂停时间
  - heap 容易出现碎片。实现中一般会进行 move 或 compact。（需要说明一点，所有 heap 回收机制都会这个问题）
  - 在 GC 工作一段时间后，heap 中连续地址上存在 age 不同的对象，这非常不利于引用的本地化（locality of reference）
  - 回收时间与 heap 大小成正比

标记-清扫垃圾回收算法

动态图遍历算法,类似于worklist算法

```
    /* 标记阶段 */
1)  把被根集引用的每个对象的 reached 位设置为 1，并把它加入
        到 Unscanned 列表中;
2)  while (Unscanned ≠ ∅) {
3)          从 Unscanned 列表中删除某个对象 o;
4)          for (在 o 中引用的每个对象 o′ ) {
5)                  if (o′ 尚未被访问到；即它的 reached 位为0) {
6)                          将o′ 的 reached 位设置为 1;
7)                          将o′ 放到 Unscanned 中;
                    }
            }
    }
    /* 清扫阶段 */
8)  Free = ∅;
9)  for (堆区中的每个内存块o) {
10)         if (o 未被访问到，即它的reached位为0)将o加入到 Free中;
11)         else 将o 的 reached 位设置为0;
    }
```

缺点:会出现很多碎片

因为语言是强类型的，所以垃圾回收机制可以知道每个数据对象的类型，以及这个对象有哪些字段是指针

标记-清扫垃圾回收算法

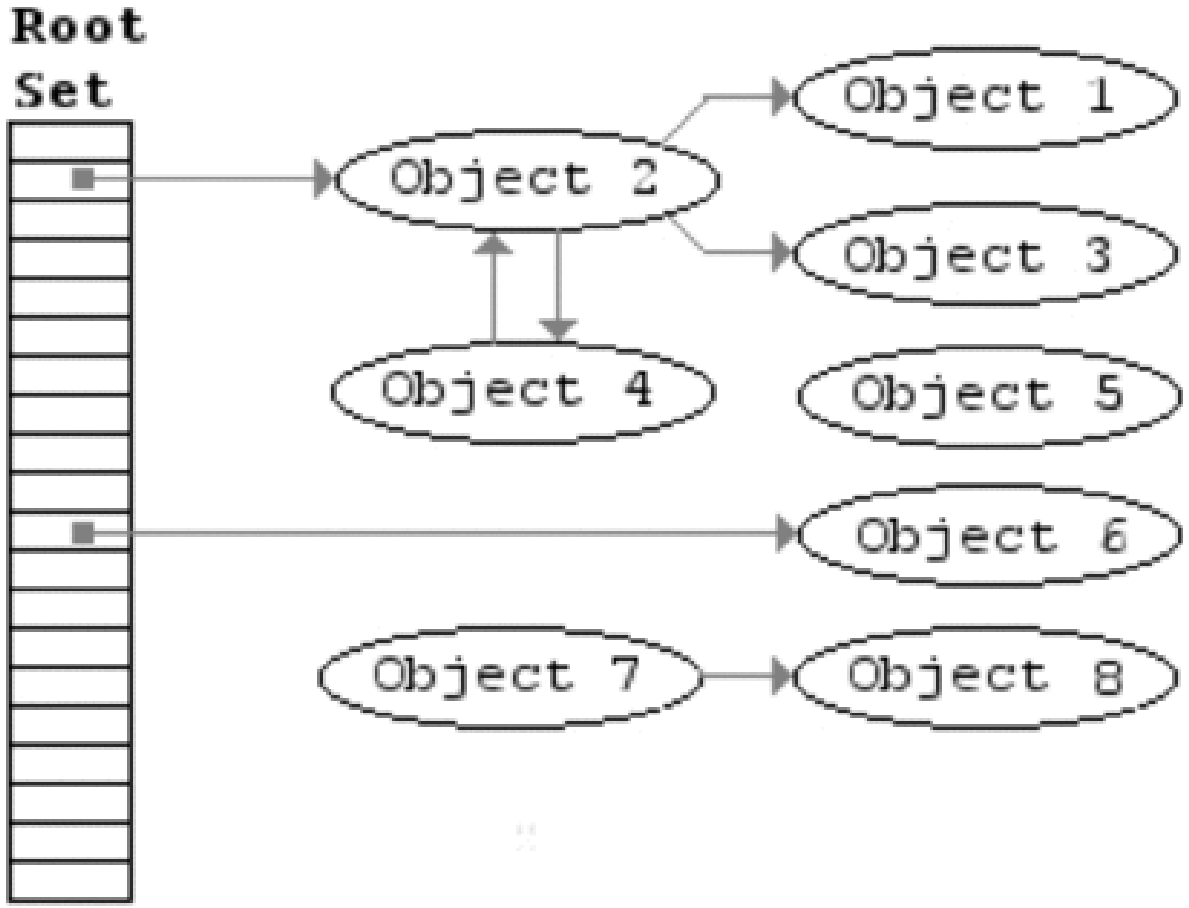
Root
Set
Object 1
Object 2
Object 3
Object 4
Object 5
Object 6
Object 7
Object 8

标记-清扫垃圾回收算法

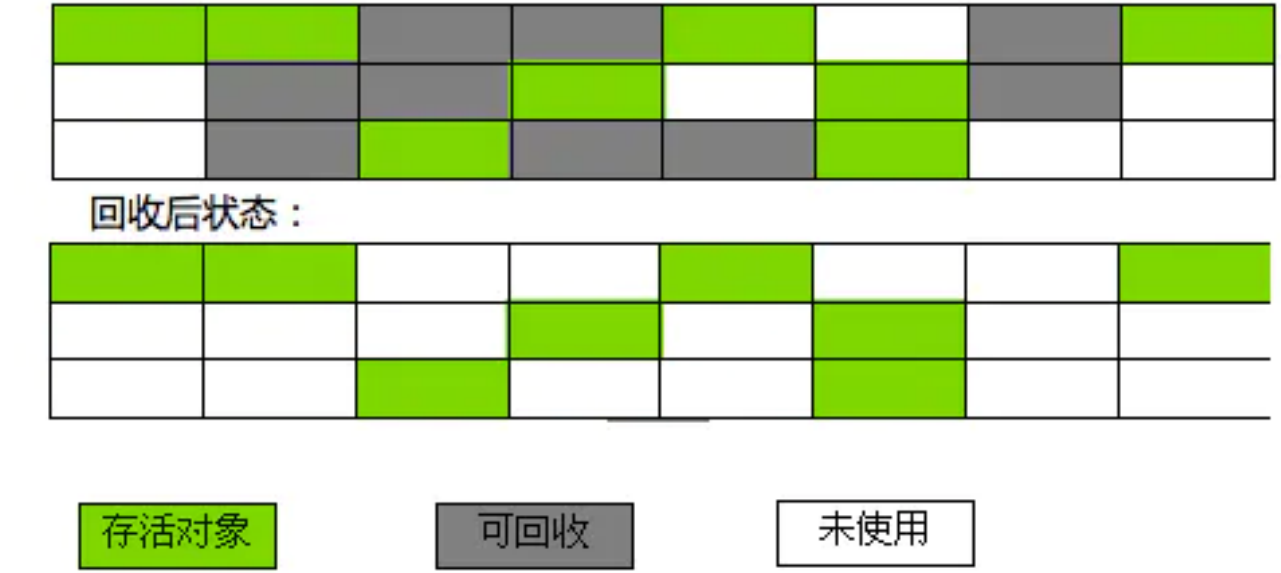

例子

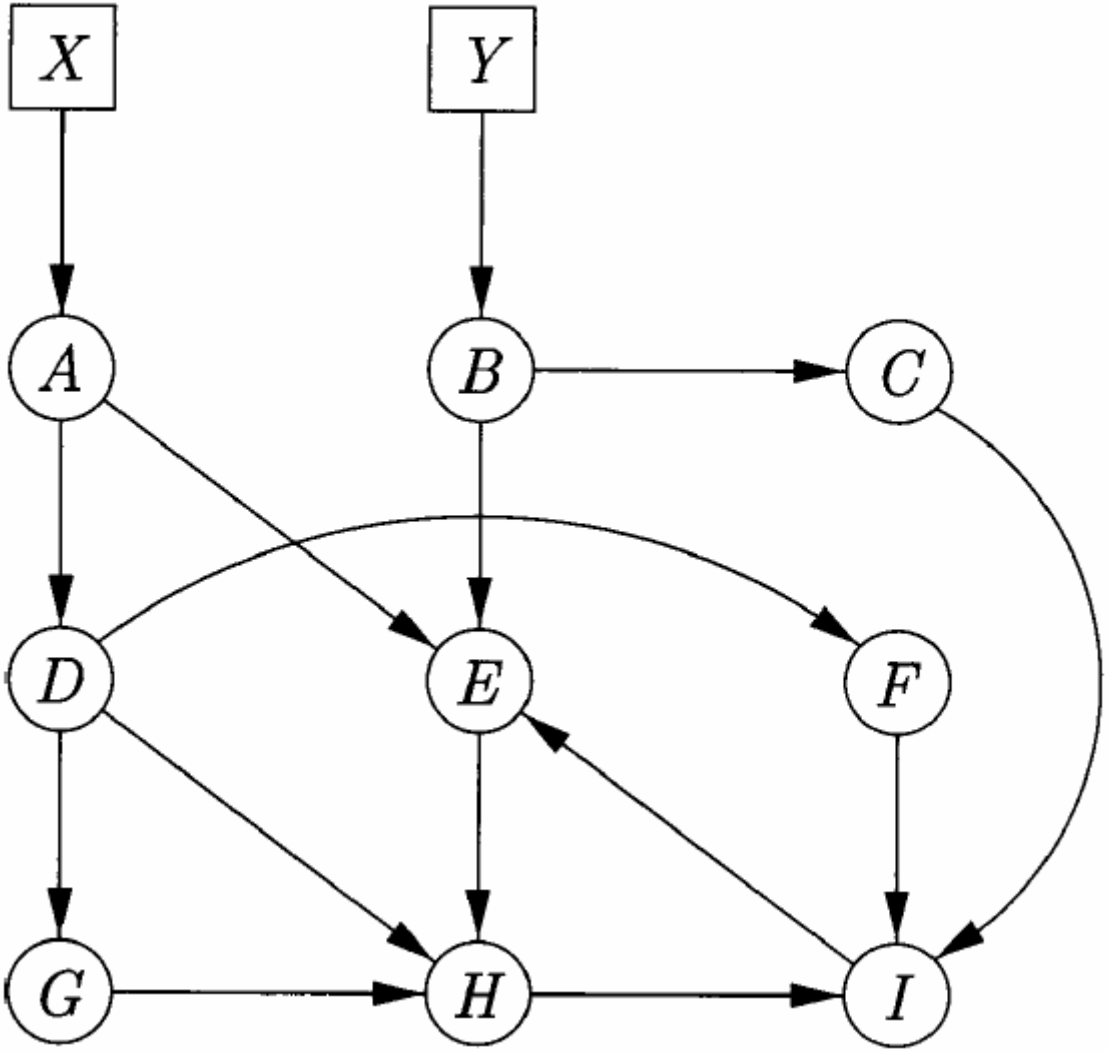

- 假设x是全局变量，y是当前函数活动的局部变量
- 当前活动返回之后，进行标记清扫
  - A，D，E，F，I，G，H
  - B，C不可达

讨论：垃圾收集的代价

- 效率！
  - 标记-清扫垃圾回收算法采用一种类似于深度优先遍历的算法，完成整个标记的过程。
  - 深度优先搜索所需的时间与它标记的节点个数成正比，即与可到达数据的数量成正比，可以推知，清扫阶段所需的时间，与堆的大小成正比。假设大小为H的堆中有R个字的可达数据。
  - 垃圾回收一次的代价则为：aR+bH，其中a与b是常数。
  - 回收一次得到的可用字空间大小为：H-R。
  - 那么，回收到一个可用字空间的代价为：

$$(aR+bH)/(H-R)$$

基本抽象分类

- 每个存储块处于四种状态之一
  - 空闲
  - 未被访问
  - 待扫描
  - 已扫描
- 对存储块的操作会改变存储块的状态
  - 应用程序分配
  - 垃圾回收器访问、扫描
  - 收回

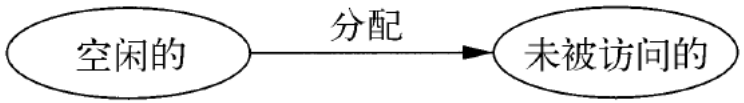

a) 跟踪之前：增变者的动作

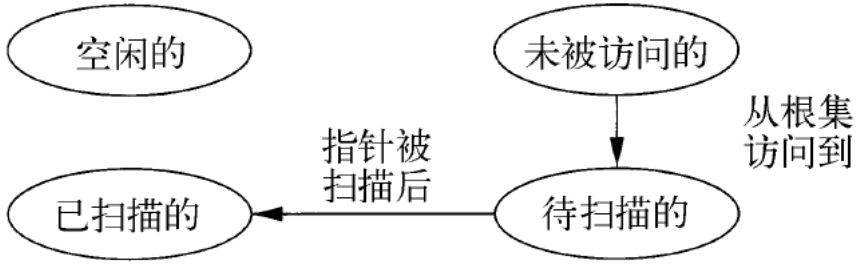

b) 通过跟踪发现可达性

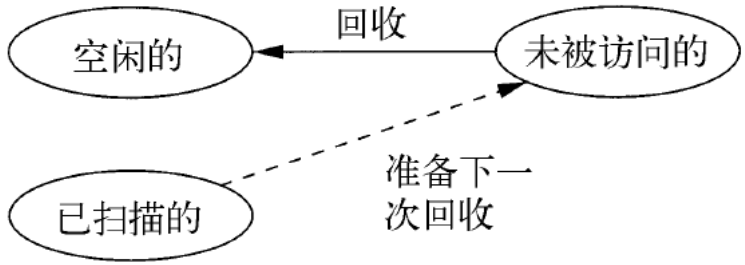

c) 回收存储空间

标记-清扫垃圾回收算法的优化

- 基本算法需要扫描整个堆
- 优化
  - 用一个列表记录所有已经分配的对象
  - 不可达对象等于已分配对象减去可达对象
- 好处
  - 只需要扫描这个列表就可以完成清扫
- 坏处
  - 需要维护这个列表

优化后的算法

- 使用了四个列表：Scanned， Unscanned, Unreached， Free；

```
1)   Scanned = ∅;
2)   Unscanned = 在根集中引用的对象的集合；
3)   while (Unscanned ≠ ∅) {
4)         将对象从 Unscanned 移动到 Scanned;
5)         for (在 o 中引用的每个对象 o′) {
6)               if (o′ 在 Unreached 中)
7)                     将o′从Unreached 移动到Unscanned 中;
           }
     }
8)   Free = Free ∪ Unreached;
9)   Unreached = Scanned;
```

压缩并标记垃圾回收

- 对可达对象进行重定位可以消除存储碎片
  - 把可达对象移动到堆区的一端，另一端则是空闲空间
  - 空闲空间合并成单一块，分配内存时高效率
- 整个过程分成三个步骤
  - 标记
  - 计算新位置
  - 移动并设置新的引用

压缩并标记垃圾回收

```
    /* 标记 */
1)  Unscanned = 根集引用的对象的集合;
2)  while (Unscanned ≠ ∅) {
3)      从 Unscanned 中移除对象o;
4)      for (在o 中引用的每个对象 o′ ) {
5)          if (o′ 是未访问的) {
6)              将o′ 标记为已访问的;
7)              将o′ 加入到列表 Unscanned 中;
            }
        }
    }
    /* 计算新的位置 */
8)  free = 堆区的开始位置;
9)  for (从低端开始，遍历堆区中的每个存储块o) {
10)     if (o 是已访问的{
11)         NewLocation(o) = free;
12)         free = free + sizeof(o);
        }
    }
```

```
    /* 重新设置引用目标并移动已被访问的对象 */
13) for (从低端开始，堆区中的每个存储块 o ) {
14)     if (o是已访问的) {
15)         for (o 中的每个引用 o.r )
16)             o.r = NewLocation(o.r);
17)         将 o 拷贝到 NewLocation(o) ;
        }
    }
18) for (根集中的每个引用 r )
19)     r = NewLocation(r);
```

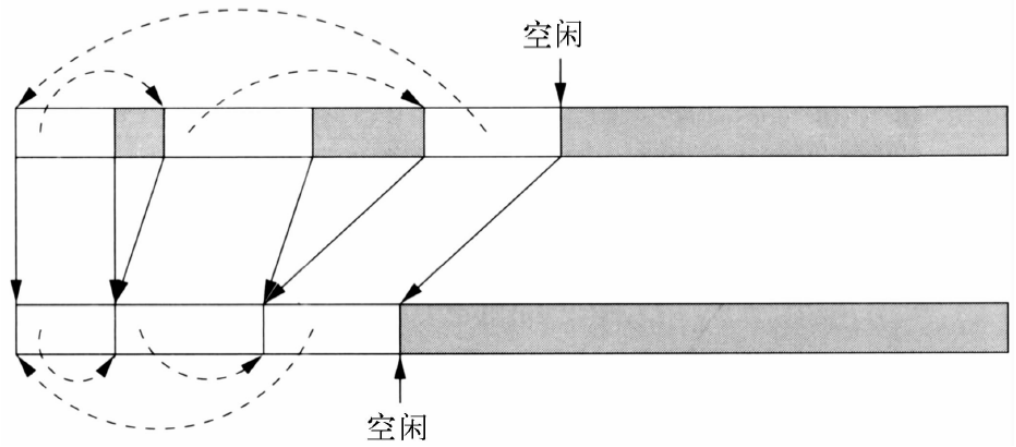

压缩并标记垃圾回收

回收前状态：

回收后状态：

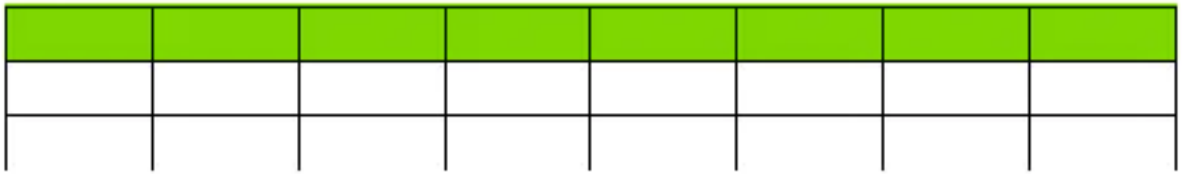

存活对象　　可回收　　未使用

拷贝回收器

- 堆空间被分为两个半空间
  - 应用程序在某个半空间内分配存储，当充满这个半空间时，开始垃圾回收
  - 回收时，可达对象被拷贝到另一个半空间
  - 回收完成后，两个半空间角色对调

只能有效地使用一半内存空间

拷贝回收器

- 拷贝回收算法虽然能解决内存碎片问题，但是需要多次遍历heap空间，这会导致较大性能损耗
- 拷贝回收算法采用空间换时间的方式来提升性能
- 这类 GC 并不会真正去“回收”不可到达对象，而是会把所有可到达对象移动到一个区域，heap 中剩余的空间就是可用的了（因为这里面都是垃圾）

拷贝回收器

- 典型的代表半空间拷贝回收器（semispace collector）。其工作过程是这样的：
  - heap 被分成2份相邻的空间（semispace）：fromspace 与 tospace
  - 在程序运行时，只有 fromspace 会被使用（分配新对象）
  - 在 fromspace 没有足够空间容纳新对象时，程序会被挂起，然后把 fromspace 的可到达对象拷贝到 tospace
  - 在拷贝完成时，之前的2个空间交换身份，tospace 成了新一轮的 fromspace

```
1)  CopyingCollector () {
2)      for (From空间中的所有对象o) NewLocation(o) =NULL;
3)      unscanned = free = To空间的开始地址;
4)      for (根集中的每个引用r)
5)          将r替换为LookupNewLocations(r);
6)      while (unscanned ≠ free) {
7)          o = 在unscanned所指位置上的对象;
8)          for (o中的每个引用 o.r )
9)              o.r = LookupNewLocation(o.r);
10)         unscanned = unscanned + sizeof(o);
        }
    }

    /* 如果一个对象已经被移动过了，查找这个对象的新位置 */
    /* 否则将对象设置为待扫描状态 */
11) LookupNewLocation(o) {
12)     if (NewLocation(o) = NULL) {
13)         NewLocation(o) = free;
14)         free = free + sizeof(o);
15)         将对象o 拷贝到 NewLocation(o);
        }
16)     return NewLocation(o);
    }
```

若文件很大，耗费的时间还是很长

拷贝回收器

回收前状态：

回收后状态：

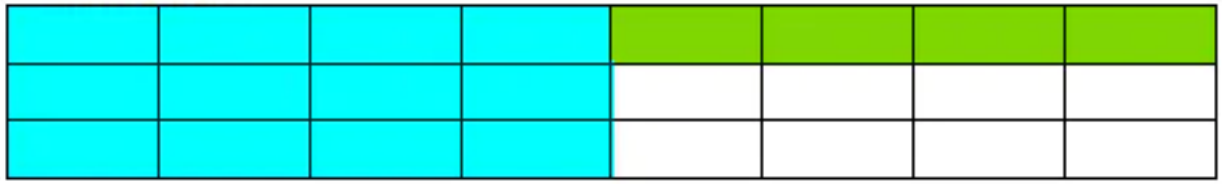

存活对象　可回收　未使用　保留区域

分代回收

- 针对很多变量存在时间较短的特点设计
- 基本思想：将堆区进行切割成块并标号，垃圾回收技术每次在较低标号的块上进行
- 具体执行方案：小范围清扫复制
  - 新对象在编号较低的堆块上创建；
  - 每次在0号堆块被填满时刻，就对0号堆块进行垃圾回收；回收完毕后，将*i*号堆块往后移动到*i+1*号堆块中
  - 维护一个记忆集，用以存储较高号的堆块对较低号堆块中对象的引用；

分代回收

- 采用该策略的基本原因：
  - 因为较年轻的世代往往包含较多的垃圾，也就更频繁地被回收；
  - 编程实践中，极少出现较老世代对较新世代的引用。因此，我们只需要记录该种情况，并定期采用其他策略进行处理即可。

GC的扩充内容

- 为什么需要 GC？
  - 计算机诞生初期，在程序运行过程中没有栈帧（stack frame）需要去维护
  - 早期内存采取的是静态分配策略，这虽然比动态分配要快，但是其一明显的缺点是程序所需的数据结构大小必须在编译期确定，而且不具备运行时分配的能力

GC的扩充内容

- GC的历史
  - Algol-58 语言首次提出了块结构（block-structured），通过在内存中申请栈帧来实现按需分配的动态策略
  - 在过程被调用时，帧（frame）会被压到栈的最上面，调用结束时弹出。栈分配策略赋予程序员极大的自由度，局部变量在不同的调用过程中具有不同的值，这为递归提供了基础
  - 后进先出（Last-In-First-Out, LIFO）的栈限制了栈帧的生命周期不能超过其调用者，而且由于每个栈帧是固定大小，所以一个过程的返回值类型也必须在编译期确定。所以诞生了新的内存管理策略——堆管理

GC的扩充内容

- GC的历史
  - C/C++/Pascal 把堆管理这个任务交给了程序员，但事实证明这非常容易出错，野指针（wild pointer）、悬挂指针（dangling pointer）是比较典型的错误
  - 实际应用的场景中，动态分配的对象传入了其他过程中，这时程序员或编译器就无法预测这个对象什么时刻不再需要，现如今的面向对象语言，这种场景更是频繁，这也就间接促进了自动内存管理技术的发展
  - 实际上，即便是 C/C++ ，也有类似 Boehm GC 这样的第三方库来实现内存的自动管理

GC的实现常见策略

- 追踪（Tracing）
  - 标记清扫（Mark-Sweep）
  - 标记压缩（Mark-Compact）
  - 拷贝（Copying）
- 引用计数（Reference counting）

JAVA的GC设计

引用类型	被垃圾回收时间	用途	生存时间
强引用	从来不会	对象的一般状态	JVM停止运行时终止
软引用	当内存不足时	对象缓存	内存不足时终止
弱引用	正常垃圾回收时	对象缓存	垃圾回收后终止
虚引用	正常垃圾回收时	跟踪对象的垃圾回收	垃圾回收后终止

JAVA的GC设计

- **JAVA 通过定义四种引用，提供了更为灵活的内存管理机制**
  - **强引用(StrongReference)**
  - **软引用(SoftReference)**
  - **弱引用(WeakReference)**
  - **虚引用(PhantomReference)**

JAVA的GC设计

- **强引用(StrongReference)：强引用是使用最普遍的引用。如果一个对象具有强引用，那垃圾回收器绝不会回收它。**

```
Object strongReference = new Object();
public void test() {
      Object strongReference = new Object();
      // 省略其他操作
  }
```

显式地设置strongReference对象为null，或让其超出对象的生命周期范围，则gc认为该对象不存在引用，这时就可以回收这个对象。具体什么时候收集这要取决于GC算法。

JAVA的GC设计

- **软引用(SoftReference)：**
  - 如果一个对象只具有软引用，则内存空间充足时，垃圾回收器就不会回收它；如果内存空间不足了，就会回收这些对象的内存。只要垃圾回收器没有回收它，该对象就可以被程序使用
  - 软引用可用来实现内存敏感的高速缓存

```
// 强引用
   String strongReference = new String("abc");
// 软引用
   String str = new String("abc");
   SoftReference<String> softReference = new SoftReference<String>(str);
```

JAVA的GC设计

- 软引用(SoftReference)：
  - 注意：软引用对象是在jvm内存不够的时候才会被回收，我们调用System.gc()方法只是起通知作用，JVM什么时候扫描回收对象是JVM自己的状态决定的。就算扫描到软引用对象也不一定会回收它，只有内存不够的时候才会回收。
  - 垃圾收集线程会在虚拟机抛出OutOfMemoryError之前回收软引用对象，而且虚拟机会尽可能优先回收长时间闲置不用的软引用对象。对那些刚构建的或刚使用过的较新的软对象会被虚拟机尽可能保留。

JAVA的GC设计

- 软引用应用场景：浏览器的后退按钮
  - 如果一个网页在浏览结束时就进行内容的回收，则按后退查看前面浏览过的页面时，需要重新构建；
  - 如果将浏览过的网页存储到内存中会造成内存的大量浪费，甚至会造成内存溢出。

JAVA的GC设计

- 软引用应用场景：浏览器的后退按钮

```
// 获取浏览器对象进行浏览
  Browser browser = new Browser();
  // 从后台程序加载浏览页面
  BrowserPage page = browser.getPage();
  // 将浏览完毕的页面置为软引用
  SoftReference softReference = new SoftReference(page);

  // 回退或者再次浏览此页面时
  if(softReference.get() != null) {
     // 内存充足，还没有被回收器回收，直接获取缓存
     page = softReference.get();
  } else {
     // 内存不足，软引用的对象已经回收
     page = browser.getPage();
     // 重新构建软引用
     softReference = new SoftReference(page);
  }
```

JAVA的GC设计

- **弱引用(WeakReference)：**
  - 弱引用与软引用的区别在于：只具有弱引用的对象拥有更短暂的生命周期。在垃圾回收器线程扫描它所管辖的内存区域的过程中，一旦发现了只具有弱引用的对象，不管当前内存空间足够与否，都会回收它的内存
  - 由于垃圾回收器是一个优先级很低的线程，因此不一定会很快发现那些只具有弱引用的对象

```
String str = new String("abc");
WeakReference<String> weakReference = new WeakReference<>(str);
String strongReference = weakReference.get();
```

JAVA的GC设计

- **虚引用(PhantomReference)：**
  - 与其他几种引用都不同，虚引用并不会决定对象的生命周期。如果一个对象仅持有虚引用，那么它就和没有任何引用一样，在任何时候都可能被垃圾回收器回收
  - 虚引用与软引用和弱引用的一个区别在于：虚引用必须和引用队列(ReferenceQueue)联合使用。当垃圾回收器准备回收一个对象时，如果发现它还有虚引用，就会在回收对象的内存之前，把这个虚引用加入到与之关联的引用队列中

JAVA的GC设计

- 虚引用应用场景：**虚引用**主要用来**跟踪对象**被垃圾回收器**回收**的活动
  - **与其他几种引用都不同，虚引用并不会决定对象的生命周期。如果一个对象仅持有虚引用，那么它就和没有任何引用一样，在任何时候都可能被垃圾回收器回收**

```
String str = new String("abc");
ReferenceQueue queue = new ReferenceQueue();
// 创建虚引用，要求必须与一个引用队列关联
PhantomReference pr = new PhantomReference(str, queue);
```